

# Machine learning algorithms for real time arrhythmias detection in portable cardiac devices: microcontroller implementation and comparative analysis

Santiago Rúa, Santiago A. Zuluaga, Alfredo Redondo, Andrés Orozco-Duque, José V. Restrepo, John Bustamante. Universidad Pontificia Bolivariana. Grupo de Investigación en Microelectrónica, Grupo de Investigación en Dinámica Cardiovascular.

**Abstract**—Category (2). This paper presents the development of two machine learning algorithms on a 32-bit ARM® Cortex® M4 microcontroller core from Freescale Semiconductors. A neural network (ANN) and a support vector machine (SVM) were implemented for real time detection of ventricular tachycardia (VT) and ventricular fibrillation (VF), and they were compared in terms of accuracy. In the feature extraction step a Fast Wavelet Transform (FWT) was used; which was analyzed using the time-frequency characteristics of energy in each sub-band frequency. For the training and validation algorithms, signals from MIT-BIH database with normal sinus rhythm, VF and VT in a time window of 2 seconds were used. Validation results achieve test accuracy of 99.46% by ANN and SVM in VT/VF detection.

**Keywords** — Arrhythmias, ECG signal, Machine Learning, Microcontroller, Neural Network, Support vector machine (SVM).

## I. INTRODUCCIÓN

La muerte súbita de origen cardíaco es una de las primeras causas de mortalidad en los países occidentales, y se debe en la mayoría de las ocasiones a arritmias cardíacas. Se calcula que el 12,5% de las defunciones que ocurren por causas naturales son debidas a muerte súbita, y de éstas el 88% son de origen cardíaco. El diagnóstico de las arritmias cardíacas se hace en primera instancia a partir del electrocardiograma (ECG), en el cual se refleja el comportamiento eléctrico del

corazón. [1].

Las arritmias cardíacas consisten en cambios en la frecuencia o el ritmo cardíaco normal, las cuales pueden ser identificadas en dispositivos de monitoreo ambulatorio mediante herramientas de procesamiento de señal basadas en derivadas, correlaciones, banco de filtros, transformadas tiempo-frecuencia [2]-[4], entre otros. Dichas herramientas se utilizan para segmentar la señal y extraer características que son utilizadas en algoritmos de clasificación o reconocimiento de patrones para establecer el tipo de arritmia que presenta el paciente.

Un sistema de procesamiento de señales se divide en las siguientes etapas: pre-procesamiento, extracción de características y clasificación. Para la etapa de clasificación, se dispone de algoritmos basados en inteligencia artificial que emulan los procesos cognitivos del hombre, como las redes neuronales, las máquinas de soporte vectorial y los modelos ocultos de Markov, comúnmente usados en reconocimiento de voz, clasificación de datos, reconocimiento de imágenes, etc [5]-[7].

Para la detección de arritmias cardíacas en tiempo real se tiene en cuenta además del desempeño del algoritmo en cuanto a su especificidad y sensibilidad, el costo computacional del mismo, teniendo en cuenta que para aplicaciones de monitoreo cardíaco ambulatorio los algoritmos deben ejecutarse en sistemas embebidos como microcontroladores, DSPs o FPGAs.

Las redes neuronales son muy utilizadas debido a su fácil implementación, que poseen un aprendizaje adaptativo, toleran fallos, es fácil su inserción dentro de las tecnologías existentes y pueden operar en tiempo real [8].

En este trabajo se compara la precisión de dos métodos de aprendizaje de máquina: red neuronal artificial (ANN) y máquina de soporte vectorial (SVM). Estos algoritmos fueron implementados en un microcontrolador de 32 bits y se evaluaron en la detección de taquicardia ventricular (VT) y fibrilación ventricular (VF), las cuales son arritmias potencialmente mortales.

Santiago Rúa, Santiago A. Zuluaga y Alfredo Redondo son estudiantes de ingeniería electrónica, miembros del Grupo de Investigación en Microelectrónica y del Grupo de Dinámica Cardiovascular de la Universidad Pontificia Bolivariana. [santiago.ruape@alfa.upb.edu.co](mailto:santiago.ruape@alfa.upb.edu.co), [santiago.alejandro@alfa.upb.edu.co](mailto:santiago.alejandro@alfa.upb.edu.co).

Andrés F. Orozco es estudiante de Doctorado y miembro del Grupo de Dinámica Cardiovascular de la Universidad Pontificia Bolivariana, [andres.orozco@upb.edu.co](mailto:andres.orozco@upb.edu.co).

José V. Restrepo, MsC. es docente investigador de la Facultad de Ingeniería de la Universidad Pontificia Bolivariana y miembro del Grupo de Investigación en Microelectrónica. [josev.restrepo@upb.edu.co](mailto:josev.restrepo@upb.edu.co).

John Bustamante, MD, Ph.D. es el director del Centro de Bioingeniería y el Grupo de Dinámica Cardiovascular y docente de la Facultad de Medicina de la Universidad Pontificia Bolivariana, Circular 1 No 70-01, [john.bustamante@upb.edu.co](mailto:john.bustamante@upb.edu.co).

## II. MATERIALES Y MÉTODOS

## A. Transformada Wavelet

Para las etapas de pre-procesamiento y extracción de características se utilizó la Transformada Rápida Wavelet (FWT) la cual puede ser vista como un banco de filtros pasa altos  $h(n)$  y pasa bajos  $l(n)$ , cuyos coeficientes dependen de la Wavelet madre seleccionada y cuya frecuencia de corte se encuentra en la mitad del espectro de la señal de entrada. El algoritmo de la FWT se muestra en el diagrama de bloques de la Figura 1. Primero se aplica la señal de entrada  $x(n)$ , a los filtros  $h(n)$  y  $l(n)$ , y después de realizar un proceso de submuestreo de la señal por un factor de dos, se obtiene el primer nivel de descomposición conformado por la señal de detalle 1,  $cD_1(n)$  y aproximación 1,  $cA_1(n)$  (que son las salidas sub-muestreadas del filtro pasa altos y el pasa bajos, respectivamente). Para obtener el segundo nivel de descomposición, se ejecuta un proceso análogo para la señal de aproximación  $cA_1(n)$ ; esta se hace pasar por los filtros  $h(n)$  y  $l(n)$  obteniendo así, la señal de detalle 2  $cD_2(n)$  y aproximación 2  $cA_2(n)$  respectivamente. Así sucesivamente se ejecuta el mismo procedimiento para las señales de aproximación obtenidas hasta el número de iteraciones requeridas para alcanzar un nivel de descomposición específico.

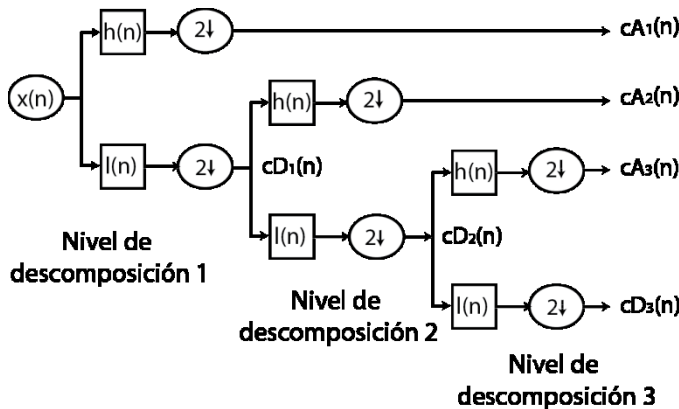


Figura 1. Diagrama de bloques de la FWT hasta un tercer nivel de descomposición.

En este trabajo se implementó la FWT con 5 niveles de descomposición utilizando una wavelet madre Symlets de orden 8, la elección de estos parámetros se basa en trabajos previos realizados por los autores [9];

## B. Energía de Sub-bandas Wavelet

Teniendo en cuenta que las patologías que se buscan detectar en este proyecto son la VT y la VF, no se utilizaron algoritmos de segmentación basados en la detección de ondas características de la señal ECG, ya que en estas patologías no se presentan estrictamente ondas P, segmentos QRS y ondas T.

La señal ECG fue segmentada por ventanas de tiempo de 2 segundos y se utilizaron como características el porcentaje de contribución de energía de los coeficientes de detalle y aproximación de las sub-bandas wavelet  $cD_3(n)$ ,  $cD_4(n)$ ,  $cD_5(n)$ , y  $cA_5(n)$ . La energía de los niveles de detalle  $cD_1(n)$  y  $cD_2(n)$ , no se tuvo en cuenta ya que estas aportan menos del 2% de la energía total de la señal.

El porcentaje de energía de cada nivel de descomposición fue calculado como se muestra en la ecuación 1:

$$E_{cD_j} = \frac{\sum_{i=1}^N cD_j(i)^2}{E_t} \times 100 \quad j = 3, 4, 5. \quad (1)$$

donde  $cD_j(i)$ , se refiere al i-esimo coeficiente del j-esimo nivel de descomposición,  $N$  es el número total de coeficientes para las cuales se calcula la energía y  $E_t$  es la energía total de la señal ECG en el intervalo de 2 segundos. El porcentaje de energía para el nivel de aproximación  $cA_5(n)$  se obtiene de manera análoga.

## C. Base de datos

Las señales ECG empleadas en el proyecto fueron obtenidas de las bases de datos “MIT-BIH Malignant Ventricular Arrhythmia Database” [10] y “MIT-BIH Normal Sinus Rhythm Database” [11]. Se utilizaron 7 señales diferentes de ECG normal, 5 de VT y 4 de VF, de las cuales se extrajeron 1163 segmentos de 2 segundos de taquicardia, 813 segmentos de ritmo normal y 1292 de fibrilación. Se utilizó el 60% de los segmentos para el conjunto de entrenamiento, 20% para la validación cruzada y 20% para el conjunto de testeo.

## D. Hardware

Para la implementación de los algoritmos se utilizó un microcontrolador Kinetis K60 con núcleo ARM® Cortex® M4 [12]. Este microcontrolador cuenta con una unidad de punto flotante que proporciona mayor exactitud a la hora de realizar cálculos que requieran de alta precisión y velocidad de procesamiento rápida (Figura 2).

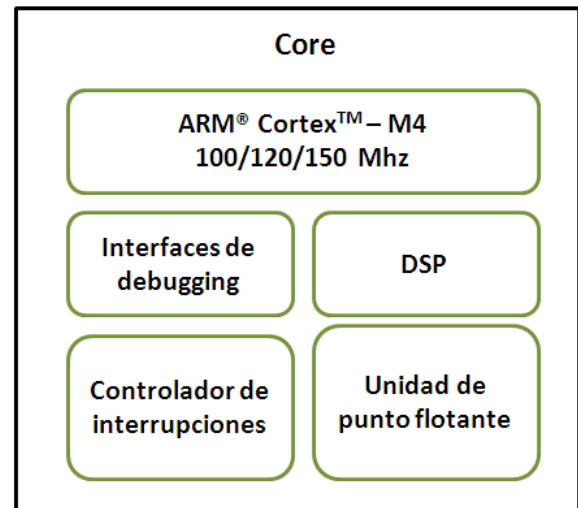


Figura 2: Esquema del núcleo Cortex-M4.

El procesador ARM® Cortex® M4 es uno de los más recientes miembros de la serie de procesadores Cortex® M, los cuales están enfocados principalmente a tareas de bajo consumo de potencia. El Cortex® M4 se basa en la arquitectura ARMv7 y cuenta con funciones de DSP (Digital Signal Processor), que lo hace óptimo para tareas en las que se requiera procesamiento en tiempo real de señales digitales [13].

### III. ALGORITMOS DE CLASIFICACIÓN

#### A. Redes Neuronales

Para la etapa de clasificación se implementó una red neuronal artificial, la cual emula el comportamiento de una red neuronal biológica. Cada neurona se modela como una red con pesos a las entradas y una función de activación [8]. La Figura 3 muestra el esquema básico de la neurona.




Figura 3. Esquema general de la neurona.

La función  $S_i$  viene dada por

$$S_i = \sum_{j=1}^n x_j W_{ij} \quad (2)$$

donde  $W_{ij}$  es el peso de entrada de la neurona y  $x_j$  es la característica de entrada.

La red neuronal artificial está compuesta por varias neuronas formando una estructura: la red neuronal implementada para la detección de arritmias cardíacas consta de una estructura de 4 capas: 1 de entrada, 2 ocultas y una de salida; dicha estructura fue seleccionada después de ensayos en MATLAB® en los cuales se buscaba minimizar el error variando los parámetros de la red en cada iteración, utilizando los datos del conjunto de correlación cruzada. La capa de entrada contiene 4 neuronas correspondientes a la energía de las cuatro bandas obtenidas a través de la Transformada Wavelet; la segunda capa y tercera poseen cada una de ellas 3 neuronas; y la cuarta tiene una sola neurona encargada de clasificar entre una condición cardíaca normal o una arritmia (VF o VT). Cada capa posee un *bias* igual a 1 (ver Figura 4).

La red neuronal artificial fue entrenada por medio del *Neural Network Toolbox™* de Matlab®, y los pesos obtenidos para la primera capa incluyendo los del *bias* son

$$W_{layer1} = \begin{bmatrix} +13.6942 & +0.4326 & +0.0403 & +0.0823 & +0.7342 \\ +2.51060 & -4.6310 & +0.2119 & +0.6442 & +0.4936 \\ +9.68950 & -0.9629 & -0.6307 & +2.0219 & -0.2652 \end{bmatrix}, \quad (3)$$




Figura 4. Arquitectura de la red neuronal implementada.

los pesos de la capa 2 son

$$W_{layer2} = \begin{bmatrix} +17.2050 & -1.4175 & +2.4593 & +6.1326 \\ +5.3072 & -0.8866 & -8.6401 & +4.4102 \\ -1.8915 & 6.6518 & +4.4547 & +4.4037 \end{bmatrix}, \quad (4)$$

y los pesos de la capa de salida son

$$W_{layout} = [+3.0015 \quad -3.8829 \quad -2.2100 \quad +3.0934]. \quad (5)$$

Las columnas de cada matriz representan los pesos de cada una de las neuronas de dicha capa; y las filas, las neuronas de la capa siguiente.

La función de activación utilizada en el algoritmo fue una función sigmoidea, función de variable real que permite describir sistemas complejos donde se describe la evolución de éstos en un determinado tiempo. Su expresión en el tiempo viene dada por

$$P(t) = \frac{1}{1 + e^{-t}} \quad (6)$$

#### B. Máquinas de Soporte Vectorial (SVM)

Se implementó una máquina de soporte vectorial (SVM), algoritmo de aprendizaje supervisado para la clasificación de datos. Si los datos de entrada se mapean por medio de una función *kernel* a un espacio n-dimensional, una SVM construirá un hiperplano o conjunto de hiperplanos de separación en ese espacio que maximiza la distancia entre los conjuntos de datos [14].

Suponiendo un conjunto como se muestra en la Figura 5, el problema a resolver de la máquina de soporte vectorial es encontrar una línea que separe los dos conjuntos y a su vez maximice la distancia entre los puntos y la línea.




Figura 5. Conjunto de entrenamiento.

Dado este conjunto existe al menos un hiperplano de la forma

$$w \cdot x + b = 0, \quad (7)$$

que separa los dos conjuntos. El problema de optimización de la SVM es entonces

$$\min_{w \in \mathbb{R}^d} \frac{1}{2} \|w\|^2. \quad (8)$$

Un posible hiperplano que cumpla esta condición para el ejemplo de la Figura 5, se muestra en la Figura 6, en donde la línea separa un conjunto del otro.

Para el entrenamiento de la SVM se utilizó el código suministrado por N. Andrew [15]. Se tomó la energía de las sub-bandas wavelet en pares para visualizar el comportamiento, y se entrenó la SVM con la energía de las 4 bandas y con el conjunto de entrenamiento. El modelo obtenido en Matlab® se llevó al microcontrolador en el cual se implementó la función de predicción.




Figura 6. Decisión de frontera obtenida a través de la SVM.

Para lograr decisiones de fronteras no lineales y más complejas se utilizaron herramientas como los *kernels*. Para la implementación de la máquina de soporte vectorial, se utilizó el *kernel* Gaussiano, dado por la expresión

$$k(x, x') = \exp\left(-\frac{\|x - x'\|^2}{2\sigma^2}\right). \quad (9)$$

#### IV. IMPLEMENTACIÓN

Para la implementación de los algoritmos en el microcontrolador, se utilizó la librería CMSIS 2.0 la cual proporciona herramientas de DSP con más de 60 funciones para operaciones de punto fijo y flotante de precisión simple (32 bit). Esta librería provee una interfaz para Cortex-M0, M3 y M4 [16]. La librería CMSIS 2.0 aprovecha una ventaja que tiene el procesador ARM® Cortex® M4, el cual cuenta con una MAC (Multiply-Accumulate), lo que le permite al procesador en un solo ciclo de reloj hacer dos operaciones, multiplicar y acumular.

##### A. Implementación de ANN

El algoritmo de predicción de la red neuronal implementado en el microcontrolador se muestra en el diagrama de bloques de la Figura 7. Este algoritmo consiste en realizar una propagación de las entradas a través de toda la red, pasando por cada uno de los pesos.

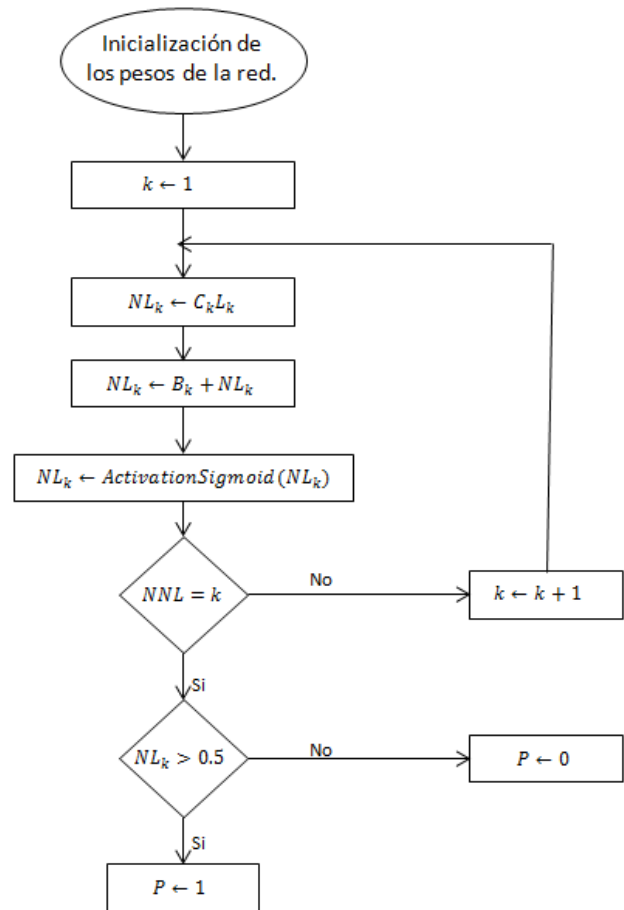


Figura 7. Diagrama de flujo para algoritmo de red neuronal.

La matriz de pesos de la capa  $k$  viene dada por  $L_k$ ,  $C_k$  es la matriz de neuronas de la capa  $k$ ,  $B_k$  es la matriz de *bias* de la capa  $k$ ,  $NNL$  es el número total de capas y  $P$  es la predicción.

### B. Máquinas de Soporte Vectorial (SVM)

En la implementación del algoritmo SVM, se obtiene primero el vector de similitudes el cual se calcula con las distancia Gaussiana entre el vector de entrada y el conjunto de entrenamiento del modelo. Una vez obtenido este vector de similitudes, se realiza el producto punto de éste con los pesos del modelo ( $\alpha$ ) y se obtiene la predicción. Si el resultado es menor que 0 se predice un caso normal y en caso contrario, un evento de taquicardia o fibrilación ventricular. La Figura 8 presenta el diagrama de flujo del algoritmo.

### V. RESULTADOS Y DISCUSIÓN

Con el fin de graficar el comportamiento de la SVM, se presenta los resultados del algoritmo utilizando solo un par de bandas como vectores de características. En la Figura 9 se visualiza el conjunto de entrenamiento para las bandas 1 ( $cA_5$ ) y 3 ( $cD_4$ ), así como la decisión de frontera dada por la SVM; y en la Figura 10 se presenta el comportamiento para las bandas 1 ( $cA_5$ ) y 4 ( $cD_3$ ).

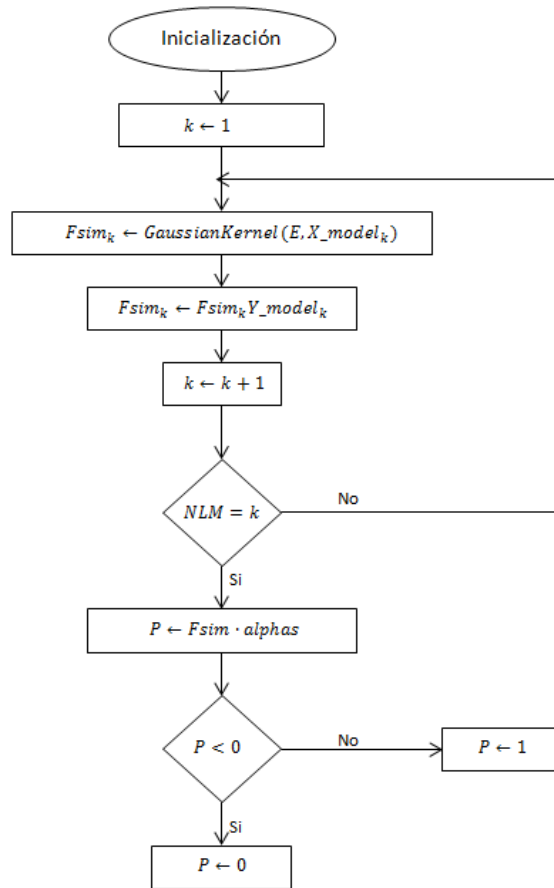


Figura 8. Diagrama de flujo para algoritmo de SVM.

Las fronteras de decisión generadas por la SVM ilustran la delimitación entre las señales ECG normales y patológicas, lo que evidencia la pertinencia del uso de la energía de las sub-bandas de frecuencia Wavelet en la detección de VF y VT. Los algoritmos para la ANN y la SVM se entrenaron previamente en MATLAB® y el resultado del modelo se

implementó en el microcontrolador. En dicha implementación se utilizaron variables tipo “float” de 32 bits. La tabla I muestra el desempeño de estos algoritmos.

Tabla I. Efectividad en la Clasificación (test).

	Precisión (%)
ANN con 4 características	99.46
SVM con 4 características	99.46

Muhammad y colaboradores, reportan un 99.70% de precisión en la detección de fibrilación ventricular offline usando la técnica de *Empirical Mode Decomposition* y teoría de decisión bayesiana, con una ventana de tiempo de 3 segundos [17]. Nuestra contribución consiste en alcanzar, en una implementación en sistemas embebidos, niveles de precisión comparables a los reportados por otros autores en el procesamiento de señales offline.

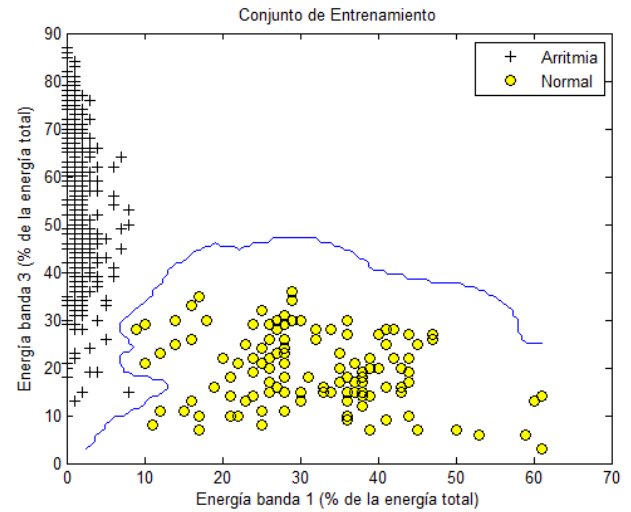


Figura 9. Conjunto de entrenamiento para las bandas de energía 1 y 3.




Figura 10. Conjunto de entrenamiento para las bandas de energía 1 y 4.

## VI. CONCLUSIONES

En este trabajo se presenta la implementación de dos métodos de aprendizaje de máquina: ANN y SVM en un microcontrolador de 32 bits para la detección en tiempo real de VT y VF usando la FWT para la extracción de características de la señal ECG.

Se obtuvo el mismo nivel de precisión con la ANN y con la SVM, sin embargo para la ANN el tiempo de ejecución es menor debido a que en el algoritmo de predicción de la ANN se ejecutan menos operaciones que en la SVM, y por lo tanto para la aplicación presentada en este trabajo se recomienda la ANN.

Los autores, están trabajando en el desarrollo de un algoritmo que permita la separación de los conjuntos que representan la VT y la VF, en este casos, la línea de frontera puede ser más compleja y el uso de la SVM podría mejorar la precisión con respecto a la ANN, razón por la cual en este trabajo se están explorando ambos algoritmos.

En este trabajo se mostró que tanto la ANN como la SVM son apropiadas para la implementación de la aplicación propuesta en microcontroladores, esto es importante ya que la utilización de clasificadores robustos como la SVM permite el desarrollo de algoritmos más complejos con el fin de realizar la detección en tiempo real de otros tipos de arritmias como los latidos ventriculares prematuros, latidos auriculares ectópicos y taqui-arritmias supraventriculares.

## REFERENCIAS

- [1] “Causes of death in 2008, *World Health Organization*, 2011. En línea: [http://www.who.int/gho/mortality\_burden\_disease/causes\_death\_2008/en/index.html.] Consultado el 16 de Octubre de 2011.
- [2] Dutta, S., Chatterjee, A., & Munshi, S. “Correlation technique and least square support vector machine combine for frequency domain based ECG beat classification”, in *Medical engineering & physics*, Vol 32 2010, pag. 1161-9.
- [3] Montes, V., Guarín, G., & Castellanos, G. “Extracción de características de ECG basadas en transformaciones no lineales y wavelets”, in *Ingeniería e Investigación*, vol. 25 2005, pag. 39-48.
- [4] Vijaya, V., Rao, K., & Rama, V. “Arrhythmia Detection through ECG Feature Extraction using Wavelet Analysis”, en *European Journal of Scientific Research*, vol 66 2011, pag. 441-448.
- [5] P. Smaragdis, B. Raj, “The Markov selection model for concurrent speech recognition”, in *Neurocomputing*, vol. 80, pp 64-72, Noviembre 2011.
- [6] G. M. Foody, A. Mathur, “Toward intelligent training of supervised image classification: directing training data acquisition for SVM classification”, in *Remote Sensing of Environment*, vol. 41, iss. 1-2, pp. 107-117, Junio 2004.
- [7] M. Chi, R. Feng y L. Bruzzone, “Classification of hyperspectral remote-sensing data with primal SVM for small-sized training dataset problem”, in *Advances in Space Research*, vol. 41, iss 11, pp 1793-1799, Noviembre 2006.
- [8] P. Larrañaga, I. Inza, A. Moujahid, “Tema 8. Redes Neuronales”, Universidad del País Vasco, Departamento de Ciencias de la Computación e Inteligencia Artificial. En línea [http://www.sc.ehu.es/ccwbayes/docencia/mmcc/docs/t8neuronales.pdf]. Consultado en Junio 11 de 2012.
- [9] A.F. Orozco, A. Redondo, F. Guzmán, J. Bustamante. “Desarrollo e implementación en FPGA de un algoritmo de reducción de ruido en señales ECG basado en wavelet”, en memorias de XV Simposio de Tratamiento de Señales, Imágenes y Visión Artificial – STSIVA 2011.
- [10] Greenwald SD. Development and analysis of a ventricular fibrillation detector. M.S. thesis, MIT Dept. of Electrical Engineering and Computer Science, 1986.
- [11] Goldberger AL, Amaral LAN, Glass L, Hausdorff JM, Ivanov PCh, Mark RG, Mietus JE, Moody GB, Peng C-K, Stanley HE. PhysioBank, PhysioToolkit, and PhysioNet: Components of a New Research Resource for Complex Physiologic Signals. *Circulation* 101(23):e215-e220 [Circulation Electronic Pages]; [http://circ.ahajournals.org/cgi/content/full/101/23/e215]; 2000 (June 13).
- [12] Freescale Semiconductor, “K60 Sub-Family Reference Manual”. En línea [http://www.freescale.com/webapp/sps/site/prod\_summary.jsp?code=K60\_100&webpageId=132640879116873314DDAF&nodeId=01624698C9DE2DDDAF&fromPage=tax]. Consultado en Junio 11 del 2012.
- [13] ARM, “Cortex-M4 Processor”. En línea [http://www.arm.com/products/processors/cortex-m/cortex-m4processor.php]. Consultado en Junio 11 de 2012.
- [14] L. Gonzales, “Modelos de Clasificación basados en máquinas de vectores”, Universidad de Sevilla, Departamento de Economía Aplicada I. En línea [http://www.asepelt.org/ficheros/File/Anales/2003%20-%20Almeria/asepeltPDF/55.pdf]. Consultado en Enero 17 de 2012.
- [15] N. Andrew, “Machine Learning class”. En línea [https://www.coursera.org/course/ml]. Consultado el 10 de Noviembre de 2011.
- [16] ARM, “CMSIS – Cortex Microcontroller Software Interface Standard”. En línea [http://www.arm.com/products/processors/cortex-m/cortex-microcontroller-software-interface-standard.php]. Consultado en Junio 12 de 2012.
- [17] A. Muhammad, J. Saeed, Md. Hasan. “Detection of ventricular fibrillation using empirical mode decomposition and Bayes decision theory” in *Computers in Biology and Medicine*, Vol. 39, pag. 1051-1057, 2009.