

Seleção de Características

Gabriel Lechenco V. Pereira

1

1. Wavelet

As transformadas wavelets podem ser vistas como similares a transformada de Fourier, porém elas contém uma característica completamente diferente: enquanto a transformada de Fourier decompõe o sinal em uma série de senos e cossenos, a transformada wavelet pode utilizar uma infinidade de funções ψ , desde que essas propriedades: ter energia finita e ter uma média igual a zero. Uma transformada wavelet pode ser representada pela seguinte notação:

$$F(a, b) = \int_{-\infty}^{\infty} f(x)\psi_{(a,b)}^*(x)dx \quad (1)$$

onde o $*$ é o símbolo para o conjugado complexo. Existem diversas famílias de funções wavelets ψ , visto que cada uma consegue extrair diferentes características de tipos de sinais distintos. A *Daubechies* é uma família comumente utilizada em sinais de Eletrocardiogramas.

1.1. Decomposição

Outra característica que diferencia a transformada utilizando funções wavelets da transformada de Fourier em processamento de sinais digitais é que, esta segunda traz o sinal do domínio no tempo para o domínio da frequência, o que dificulta a análise de sinais muito longos e com variações de frequência. Em contrapartida, a transformada wavelet transforma o sinal de seu domínio no tempo para um domínio no tempo e na escala, fornecendo então novas oportunidades de análise de sinais. A figura 1 exemplifica essas diferenças.

Com essas propriedades, é comum interpretar a transformada wavelet como um conjunto de filtros passa-baixa e passa-alta, realizando a decomposição do sinal por níveis. A cada nível, o sinal é dividido em duas partes: a aproximação (filtro passa-baixa) e os detalhes (filtro passa-alta). Sendo que a frequência de corte é reduzida por um fator de 2 a cada nível. Dessa forma, se o nosso sinal original tem uma frequência de amostragem $f_c = 128Hz$, e decompomos o sinal até o quarto nível, cada nó folha da árvore de decomposição representa cerca de $8Hz$ do sinal original.

2. Correntropia

A Correntropia trata-se de uma função de correlação que permite fazer a correlação de processos aleatórios, sendo diretamente relacionado com a probabilidade de duas variáveis serem similares. Sua definição mais geral é representada pela equação 2.

$$V(X, Y) = E[< \Phi(X), \Phi(Y) >] = E[k(X - Y)] \quad (2)$$

A equação de correntropia é maximizada quando X e Y são similares, para isso ela reduz naturalmente o impacto de pontos de *outlier* e ruídos irrelevantes. Portanto, em




Figure 1. Resolução no tempo e frequência para diferentes tipos de sinais

várias aplicações a função de correntropia demonstra um resultado melhor do que outras técnicas mais consolidadas, como o Erro Quadrático Médio (MSE) por exemplo.

Entretanto, a função de correntropia depende do ajuste do tamanho do kernel $\sqrt{2}\sigma$, o qual pode ser interpretado como um parâmetro de sensibilidade da função. Atualmente não existe um método satisfatório para se encontrar o melhor valor de σ para um determinado tipo de sinal, sendo este processo totalmente empírico.

3. Características

O mais importante para se utilizar uma técnica de machine learning é a escolha de quais características e propriedades serão inseridas no algoritmo para serem analisadas, construindo assim o aprendizado. Se a quantidade de características for pequena, o tempo de processamento necessário para o algoritmo também será reduzido, entretanto, essas características devem ser relevantes para o problema e para a técnica utilizada, para a obtenção de melhores resultados. Dessa forma, ao se utilizar características que representam propriedades irrelevantes, ou até redundantes para o tema abordado, podemos não ver uma melhoria na classificação mesmo aumentando em muito o número de dimensões analisadas, podendo até mesmo piorar a performance e os resultados finais.

O problema em questão trata da classificação de Eletrocardiogramas patológicos e saudáveis utilizando máquinas de vetores de suporte (SVM). Entretanto, uma abordagem mais direta utilizando o sinal íntegro como vetor de características pode ser vista como problemática pelos critérios mencionados acima. Ao inserir todos os pontos do sinal no classificador estamos inserindo um grande número de dimensionalidades desnecessárias e redundantes, aumentando em muito o custo computacional para um resultado que pode não ser satisfatório.

3.1. Energia das Wavelets

Uma propriedade muito utilizada ao analisar sinais de ECG e que já se mostrou eficaz em outros trabalhos da literatura, a energia das folhas wavelet nos permite analisar quais faixas de frequência apresentam uma maior influência sobre o sinal original. Oferecendo uma única medida para cada folha, reduzindo então o sinal de 1024 pontos para 2^n valores de energia, sendo n o número de níveis de decomposição das wavelets.

Em um primeiro momento foram testados diferentes níveis de decomposição e se chegou a conclusão de que, não é tão vantajoso descer mais do que quatro níveis, decorrente que o custo computacional intensificado não é compensado pelo ganho nos resultados finais. Entretanto, tendo em vista um sinal de ECG e os efeitos de arritmia, os quais afetam as frequências mais baixas, teorizou-se que ao decompor somente a primeira folha do quarto nível, por mais dois níveis, e se adicionar suas energias ao vetor de características, poderíamos ter uma melhora significativa nos resultados.

3.2. Correntropia em sinais reconstruídos

Uma outra teoria abordada seria o cálculo de correntropia entre o sinal original e o sinal gerado por cada uma das folhas das wavelets reconstruído. Porém, como dito anteriormente, um grande problema da correntropia é encontrar o tamanho do kernel σ mais adequado para o sinal analisado. Por isso, rodou-se uma bateria de testes para diversos valores de sigma, esperando encontrar alguma melhora significativa durante as execuções. Esta porém não é uma atividade trivial, já que a manipulação de árvores wavelet, reconstruindo diversas vezes o sinal se vê muito custosa, levando severos minutos para o teste de apenas um possível valor para σ .

Tendo em vista a importância da seleção destas propriedades para o sucesso do algoritmo de classificação, foram realizados diversos testes alternando as características que seriam inseridas no algoritmo a fim de eleger a melhor configuração para o problema em questão. Foram quatro as configurações utilizadas:

- Coeficientes de energia wavelet do quarto nível de decomposição (16 características);
- Coeficientes de energia wavelet do quarto nível + expansão da primeira folha em mais dois níveis (20 características);
- Coeficientes de energia wavelet do quarto nível + expansão da primeira e segunda folha em mais dois níveis (24 características);
- Coeficientes de energia wavelet e correntropia do sinal reconstruído para o quarto nível de decomposição (32 características).

4. Resultados Preliminares

Com as técnicas descritas anteriormente e os cenários definidos foram preparados testes para analisar a performance para cada caso. Estes testes consistem em extrair a média dos resultados durante 30 execuções do algoritmo de classificação, o resultado pode ser visto na tabela 1.

Os resultados nos mostram uma relevante melhora nos resultados ao expandir as primeiras folhas da wavelet em outros dois níveis, corroborando com a ideia de que esses nós têm grande influência sobre o sinal de ECG. Entretanto, nota-se apenas um

	Acurácia	Precisão	Recall	F1score
Wavelet Quarto nível	0.9127	0.9216	0.9056	0.9135
Wavelet + expansão da primeira folha	0.9456	0.9377	0.9528	0.9452
Wavelet + expansão das duas primeiras folhas	0.9508	0.9395	0.9611	0.9502
Wavelet + Correntropia	0.9123	0.9239	0.9030	0.9133

Table 1. Resultados médios da execução dos testes

pequeno acréscimo nas métricas entre expandir somente a primeira folha e expandir as duas primeiras, apesar de existir uma melhoria, para uma aplicação real com um intervalo de tempo muito curto este processamento a mais pode ser visto como desnecessário.

Em relação ao uso da correntropia em conjunto com as energias wavelet, este não apresentou nenhum ganho para com o cenário que utiliza apenas das energias wavelet. Podendo ser justificado pelo ajuste da correntropia feito pelo tamanho do kernel σ , como este deve ser encontrado empiricamente então o valor utilizado pode não ser o melhor para os sinais estudados, não influenciando positivamente na classificação.

5. Conclusão

O estudo mostrou a eficiência das transformadas wavelet e seus índices de energia para a separação de sinais de ECG em duas classes, com e sem arritmia. Além disso, o aumento da acurácia e precisão ao se expandir as primeiras folhas da árvore de decomposição reafirmam a influência das baixas frequências no diagnóstico de sinais arrítmicos. Portanto, podemos encarar como indo na direção correta.

Entretanto, os testes com a correntropia não apresentaram resultados tão satisfatórios, devido ao ajuste do valor de σ . Como este valor traz um comportamento específico para cada sinal, novos testes devem ser realizados para tentar achar valores mais eficazes. Focar mais um pouco no estudo deste tópico e não o descartá-lo de imediato se justifica já que a correntropia oferece algumas propriedades interessantes para sinais digitais, como o descarte de ruídos e *outliers*.